
Label 6: Deep Q-Network and Deep Deterministic Policy Gradient


1. 訓練 DQN - CartPole-v1 的 10,000 epoch 時的分數與數據狀況

```
"e:9995, reward:500.0"
"e:9996, reward:500.0"
"e:9997, reward:500.0"
"e:9998, reward:500.0"
"e:9999, reward:500.0"
```



2. 訓練 DDPG - Pendulum-v0 的 3,000 epoch 時的分數與數據狀況

```
e:2995,Length:200,reward:-372.6622963674208
e:2996,Length:200,reward:-125.07216749615071
e:2997,Length:200,reward:-742.304199905537
e:2998,Length:200,reward:-233.448590134766
e:2999,Length:200,reward:-237.5385228384982
```



3. DQN 實作

a.DQN網路架構

b. optimizer 使用 Adam, 其中 betas 有額外改參數, criterion 的使用 MSE loss 才能符合公式。

```
optimizer = optim.Adam(behavior_net.parameters(), lr = args.lr, betas = (5e-1, 999e-3))
criterion = nn.MSELoss()
```

C. 選擇動作有機率是隨機以外, 因為輸出分別是往左或往右的機率, 所以選最大的並強轉 int 傳出去。

```
def select_action(epsilon, state, action_dim=2):
    """epsilon-greedy based on behavior network"""
    if random.random() < epsilon:
        return random.randint(0, action_dim-1)
    else:
        return int(behavior_net(state).max(0)[1])</pre>
```

d. 更新網路的部份,先將 replay buffer 的資料隨機的 sample 出來後,在用 behavior 網路輸出往左往右的機率,根據當時所選的動作產生 q_value,在使用不更新的 target 網路用 Q learning 的方式算出 q_next,最後在用 MSE 算誤差,其中很有意思的是有做 clip_grad_norm 來將一部分的 gradient 捨棄掉,來使訓練不容易收 斂在一個不好的地方。

```
def update_behavior_network():
    def transitions_to_tensors(transitions, device=args.device):
        """Convert a batch of transitions to tensors"""
        return (torch.Tensor(x).to(device) for x in zip(*transitions))

# sample a minibatch of transitions
transitions = memory.sample(args.batch_size)
state, action, reward, next_state, done = transitions_to_tensors(transitions)

q_value = behavior_net(state).gather(1, action.long())
with torch.no_grad():
        q_next = reward + args.gamma * target_net(next_state).max(1)[0].view(args.batch_size, 1) * (1 - done)

loss = criterion(q_value, q_next)

# optimize
optimizer.zero_grad()
loss.backward()
nn.utils.clip_grad_norm_(behavior_net.parameters(), 5)
optimizer.step()
```

e. train —開始會先等 replay buffer 存儲到一定的量後才開始讓DQN動作,每隔幾個步驟更新一次 behavior 網路,再每隔幾個步驟後直接完整更新 target 網路。

f. test 時就每一步驟都由 behavior 來掌控著。

```
def test(env, render):
 print('Start Testing')
 epsilon = args.test_epsilon
 seeds = (20190813 + i for i in range(10))
 average = 0.0
 for seed in seeds:
   total_reward = 0
   env.seed(seed)
   for t in itertools.count(start=1):
     state_tensor = torch.Tensor(state).to(args.device)
     action = select_action(args.test_epsilon, state_tensor)
next_state, reward, done, _ = env.step(action)
     state = next_state
     total_reward += reward
     total_steps += 1
       average += total_reward
 print("Average Reward:{}".format(average/10))
```

4. DDPG 實作

a. ActorNet 網路架構, hidden 維度調整成 512 x 256。

b. CriticNet 網路架構, hidden 維度調整成 512 x 256, 以及多了一個 action_head, 將 action 維度拉高, 最後在進入 critic 時在與 cirtic head 輸出串連起來。

```
def __init__(self, state_dim=3, action_dim=1, hidden_dim=(512, 256)):
 super().__init__()
 h1, h2 = hidden dim
 self.critic head = nn.Sequential(
     nn.Linear(state dim, h2, False),
     nn.ReLU(),
 self.action head = nn.Sequential(
   nn.Linear(action dim, h2, False),
   nn.ReLU()
 self.critic = nn.Sequential(
     nn.Linear(h1, h2, False),
     nn.ReLU(),
     nn.Linear(h2, action_dim, False)
def forward(self, x, action):
 x = self.critic_head(x)
 a = self.action head(action)
  return self.critic(torch.cat([x, a], dim=1))
```

c. 參數設定改了 episode 的數量到 3,000 和 batch_size 為 256。

```
def parse args():
  parser = argparse.ArgumentParser(description= doc )
  parser.add argument('-d', '--device', default='cuda')
 # network
  parser.add argument('-m', '--model', default='./DDPG.pt')
  parser.add argument('--restore', action='store false')
  parser.add argument('-e', '--episode', default=3000, type=int)
  parser.add argument('-c', '--capacity', default=10000, type=int)
  parser.add argument('-bs', '--batch size', default=256, type=int)
  parser.add argument('--warmup', default=10000, type=int)
  parser.add argument('--lra', default=1e-4, type=float)
  parser.add argument('--lrc', default=1e-3, type=float)
 parser.add_argument('--gamma', default=.99, type=float)
  parser.add argument('--tau', default=.001, type=float)
 parser.add argument('--render', action='store true')
  return parser.parse args()
```

d. optimizer 選用 Adam 和 criterion 用 MSE。

```
actor_opt = optim.SGD(actor_net.parameters(), lr = args.lra)
critic_opt = optim.SGD(critic_net.parameters(), lr = args.lrc)
criterion = nn.MSELoss()
```

e. 選步的時候只有在 train 的時候會加上 OU, test 的時候不使用。

```
def select_action(state, low=-2, high=2, train = True):
    """based on the behavior (actor) network and exploration noise"""
    with torch.no_grad():
        action = actor_net(state)

if train:
        action += random_process.sample()

action = action.cpu()
    return max(min(action, high), low)
```

f. update netwark 的先更新 critic 網路,符合更新公式,但我有額外針對如果是 terminal 的時候,只會剩下 reward,讓公式比較符合 Q-Learning, actor 完全比照公式的方式,其中有多乘上-1來使梯度可以下降。

```
def update behavior network():
 def transitions to tensors(transitions, device=args.device):
   return (torch.Tensor(x).to(device) for x in zip(*transitions))
  transitions = memory.sample(args.batch_size)
 state, action, reward, state_next, done = transitions to tensors(transitions)
 q value = critic net(state, action)
 with torch.no grad():
   a_next = target_actor_net(state_next)
   q_next = reward + args.gamma * target_critic_net(state_next, a_next) * (1 - done)
 critic_loss = criterion(q_value, q_next)
 actor net.zero grad()
 critic_net.zero grad()
 critic_loss.backward()
 critic_opt.step()
 ## update actor ##
 actor loss = -1 * torch.mean(critic net(state, action))
 # optimize actor
 actor_net.zero_grad()
 critic net.zero grad()
 actor loss.backward()
 actor_opt.step()
```

g. 更新 target 網路的方式與公式相同。

```
def update_target_network(target_net, net):
    tau = args.tau
    for target, behavior in zip(target_net.parameters(), net.parameters()):
        target.data.copy_(tau * behavior.data + (1 - tau) * target.data)
```

h. test 的時候只要使用 actor 網路選動作即可。

```
def test(env, render):
 print('Start Testing')
  seeds = (20190813 + i \text{ for } i \text{ in range}(10))
 average = 0.0
  for seed in seeds:
   total reward = 0
   total steps = 0
   env.seed(seed)
    state = env.reset()
    for t in itertools.count(start=1):
     state tensor = torch.Tensor(state).to(args.device)
     action = select_action(state_tensor, train=False)
     next state, reward, done, = env.step(action)
     state = next state
     total reward += reward
      total steps += 1
     if done:
        average += total reward
        print('Step:{},Length:{},reward:{}'.format(total steps, t, total reward))
        break
 average /= 10
 print("Average Reward:{}".format(average))
  env.close()
```

5. 回答問題

- a. DQN與DDPG的不同在於, DDPG實現了Actor-Critic的概念,將 policy gradient 在 Actor網路架構中去處理, Value based則就在 Critic網路架構中處理,解決連續狀態問題,基於DQN的 replay buffer和 Target網路的方式,其中更新 Target網路 DDPG也不同於 DQN,更新時會用 Soft的方式來延遲更新。
- b. discount factor 取決於對於未來的價值比例有多重,當 discount factor 越大,也就看下一個狀態所能得到的回饋就看得 越高,也更能夠知道選的這一動作是否能獲取更往好的目標前進。
- c. epsilon-greedy 好處在於可以協助網路作到探索的功能, 如果一直都是只選最好的, 很容易會陷入到一個收斂瓶頸, 導致學習狀況沒有辦法有更好的表現, 那有機率去選擇到沒有看過得, 可以跳脫這瓶頸。
- d. 因為 RL 不同 epoch 的 state 變畫會導致 Q-network 產生的結果分佈是非靜態的, 從而導致訓練出的結果不穩定, 那麼 target 網路就是為了解決這樣非靜態的問題, 來使訓練結果更加穩定。
- e. Replay buffer 如果太小其實就近乎沒有 replay buffer 的意義, replay buffer 是為了要解決一直往某一個 gradient 的可能性, 也可說是模糊 model-based 和 model-free 的界線, 如果太大那要能學習到很好的狀態, 也要花費更多的時間去學習才行。

f. 因為 DDPG 是在處理連續環境下運作的, 那會與時序有很大的關聯, 那麼 OU 這個算法根據時序以及先前的 random 狀態去做相對性的調整, 會比 normal noise 來的更加平滑且穩定。

5. DQN - CartPole-v1 測試結果為平均 500.0

Step:500, reward:500.0 Step:500, reward:500.0

6. DDPG - Pendulum-v0 測試結果為平均 -219.5

```
Step:200, Length:200, reward:-118.71331024169922
Step:200, Length:200, reward:-243.0944366455078
Step:200, Length:200, reward:-125.35185241699219
Step:200, Length:200, reward:-0.4142301678657532
Step:200, Length:200, reward:-125.93205261230469
Step:200, Length:200, reward:-347.29974365234375
Step:200, Length:200, reward:-508.76483154296875
Step:200, Length:200, reward:-125.37564849853516
Step:200, Length:200, reward:-474.3575439453125
Step:200, Length:200, reward:-125.69444274902344
Average Reward:-219.4998016357422
```